

공연 메타데이터 챗봇화 프로세스 정립 가이드

Standard Operating Procedure (SOP)

v1.0 · 2026.06

본 문서는 공연 데이터를 챗봇이 활용 가능한 메타데이터로 가공한 전 과정과,
향후 재활용 가능한 표준 프로세스(7단계)를 정리한 운영 가이드입니다.

[■] 프로젝트 개요

항목	내용
목표	외부 공공/민간 콘텐츠 목록(예: 문화체육관광부 공연정보)을 챗봇 학습용 메타데이터로 가공
입력	비정형 JSON 또는 CSV (필드명 · 구조 통일되지 않음)
출력	19개 컬럼 정형 데이터 (Excel + CSV) — DB 적재 및 챗봇 시스템 프롬프트 즉시 활용
소요 단계	7단계 (입력 정제 → 분류 → 보강 → 풍부화 → 페르소나 → 프롬프트 → 검증)
결과 활용	상품 상세 페이지(HTML), 카테고리 필터링, AI 챗봇 페르소나, 검색 · 추천 시스템

[■] 7단계 표준 프로세스 (Stage 1 ~ 7)

Stage 1. 원천 데이터 수집 및 1차 파싱

1-1. 원천 데이터 식별

- 공공 API / 웹 스크래핑 결과물 / 수기 CSV 등 다양한 소스를 수용
- 본 프로젝트에서는 extracted_lists.json (중첩 리스트, 100건)

1-2. 필드 매핑 규칙 수립

- 원본 필드를 표준 필드명(prdt_tit, prdt_desc, prdt_optn_001 등)으로 매핑
- prdt_optn_001 ~ 010 슬롯을 미리 예약 → 도메인 변경에도 컬럼 구조 유지

1-3. 텍스트 정규화 (필수!)

- 모든 줄바꿈(\r\n, \r, \n) · 탭 · 연속 공백 제거 → 단일 라인화
- CSV 깨짐의 가장 큰 원인은 셀 내부 줄바꿈

[*] 재사용 팁: prdt_optn 슬롯을 미리 예약해두면, 도메인이 바뀌어도 컬럼 구조 그대로 유지 가능

원본 필드	표준 필드명	용도
title	prdt_tit	상품/공연 제목
description	prdt_desc	원본 HTML 설명
url	prdt_href_url	상세 페이지 링크
imageObject	prdt_thumb_src	썸네일 이미지
eventSite	prdt_place	장소
eventPeriod	prdt_optn_001	기간 문자열
eventPeriod (시작)	prdt_apply_at_st	YYYYMMDD 형식
eventPeriod (종료)	prdt_apply_at_en	YYYYMMDD 형식
contactPoint	prdt_contact	문의처

Stage 2. 카테고리(지역) 자동 분류

2-1. 분류 기준 마스터 데이터 정의

- ctgr_id 체계 (8자리 코드): 20260004 서울 / 20260007 부산 / ... / 20260023 기타
- 마스터 코드는 향후 다른 데이터셋과 통합 시 일관성 보장

2-2. 3-Tier 매칭 알고리즘 (우선순위)

1순위: 특수 규칙 (예: '세종문화회관' → 서울, '경기 광주' → 경기)

2순위: 장소(prdt_place) 키워드 매칭

3순위: 연락처(prdt_contact) 키워드 매칭

4순위: 제목(prdt_tit) 키워드 매칭

→ 모두 실패 시 '기타' 카테고리로 폴백

2-3. 분류 결과 검증

- '기타'로 분류된 항목을 출력해 사람이 1차 확인
- 키워드 사전을 지속 보강 → 다음 회차 정확도 향상

[*] 재사용 팁: 지역·산업·테마 등 어떤 분류 체계든 이 3-Tier 알고리즘은 그대로 활용 가능

Stage 3. 외부 페이지 스크래핑 보강

3-1. 상세 페이지에서 추가 데이터 추출

- 본 프로젝트: 문체부 페이지에서 분야 / 시간 / 요금 추출
- 정형화된 페이지 구조 활용: <dt>/<dd> 또는 라벨 기반 정규식

3-2. 3중 안전망 파싱 로직

- 1) <dt>/<th> 페어 추출 (가장 신뢰)
- 2) /<div> 내부 '라벨 + 값' 패턴 매칭
- 3) 전체 텍스트 정규식 추출 (최후 수단)

3-3. 정규화 규칙

- '무료' 또는 빈값 → 0
- '-' 또는 '없음' → 0 (또는 '문의')
- '전석 30,000원' → 원문 유지

3-4. 환경 분리: 샌드박스 ↔ 로컬 실행

- 보안/네트워크 제약이 있을 때: 로컬에서 실행 가능한 Python 스크립트 패키지로 제공
- 패키지 구성: 스크립트 + requirements.txt + 사용법 안내

[*] 재사용 팁: enrich_performance.py 같은 보강용 스크립트 템플릿을 한 번 만들어두면, URL만 바꿔 재사용 가능

Stage 4. 휴리스틱 분류 (분야 자동 추론)

4-1. 키워드 기반 분야 매핑 (우선순위 중요)

1. '뮤지컬' → 뮤지컬
2. '오페라' → 오페라
3. '발레/안무' → 무용
4. '전시/개인전/갤러리/미술관' → 전시
5. '국악/판소리/해금' → 국악
6. '축제/페스티벌' → 축제
7. '콘서트' → 콘서트
8. '합창/오케스트라/리사이틀/정기연주회' → 음악
9. '연극/극단/씨어터/소극장' → 연극
10. 기본값 → 공연

4-2. 매칭 순서가 핵심

- 더 구체적인 키워드를 먼저 검사 (예: '뮤지컬 콘서트'는 콘서트가 아니라 뮤지컬)
- 잘못 분류된 케이스는 키워드 사전을 보강해 다음 회차에 반영

[*] 재사용 팁: 도메인이 바뀌어도 '우선순위 키워드 + 기본값' 패턴은 동일하게 적용 가능

Stage 5. 콘텐츠 풍부화 (시대 배경 · 줄거리 · 캐릭터)

5-1. 캐릭터 정보 (prdt_optn_007) — JSON 배열

- 형식: [{'name': '캐릭터명', 'attr': '성격을 상세하게'}]
- 작품 주연 · 조연 4~5명 선정
- 시대적 배경 + 성격 + 작품 내 역할 포함
- 챗봇 1인칭 페르소나로 말할 수 있을 만큼 구체적으로
- 적용 대상: 희곡 · 뮤지컬 · 오페라 · 동화 등 (콘서트 · 전시는 빈 값)

5-2. 시대 배경 (prdt_optn_009) — 3-Tier 작성 전략

역사/고전 원작: 시기 · 지명 · 역사적 맥락 상세 (예: '조선 명종~선조 연간, 1586년 안동...')

작가 명확 동시대 작품: 작가의 작업 시기 (예: '1985~2005년 제주도, 김영갑 작가...')

일반 공연/연주회: 분야별 표준 문구 적용

5-3. 핵심 줄거리 (prdt_optn_010) — 2~4문장 시놉시스

- 기-승-전-결 구조로 압축
- 주요 등장인물의 행동 · 동기 포함
- 핵심 갈등과 해결 명시
- 일반 공연은 분야별 표준 안내문

5-4. 풍부화 데이터 수집 전략

- 1) AI 사전 지식 활용 (벚꽃동산 · 투란도트 등 고전)
- 2) 웹 검색으로 사실 확인 (특히 인물 · 시대 · 연도)
- 3) 도메인 전문가가 보강

[*] 재사용 팁: 풍부화 사전(CCHARACTERS, ERA_MAP, PLOT_MAP)을 별도 JSON 파일로 분리 관리하면, 코드 변경 없이 콘텐츠만 업데이트 가능

Stage 6. 상품 상세 HTML 자동 생성 (prdt_ctts)

6-1. 컴포넌트 기반 HTML 설계 (섹션 순서)

- ① 썸네일 이미지
- ② 분야 배지 + 지역 배지
- ③ 타이틀
- ④ 정보 그리드 (기간 / 시간 / 장소 / 요금 / 문의)
- ⑤ 시대 배경 박스 (amber)
- ⑥ 핵심 줄거리 박스 (green)
- ⑦ 등장인물 박스 (rose, n명)
- ⑧ 공연 소개 (원본 desc)
- ⑨ 자세히 보기 → 버튼

6-2. 스타일링 원칙

- Tailwind CSS 클래스 사용 (외부 사이트 호환)
- 컬러 코딩으로 정보 유형 구분 (시대=amber, 줄거리=green, 인물=rose)
- 그라데이션 · 배지 · 아이콘으로 시각적 매력 강화
- 모든 HTML은 단일 라인으로 압축 (CSV 호환성)

6-3. 표시 가공 로직

- 요금 = 0 → '무료'
- 요금 = '-' → '문의'
- 문의처 = '-' → '문의처 정보 없음'
- 시간 = 빈값 → '공연일정 참고'

[*] 재사용 팁: HTML 템플릿을 Jinja2 같은 템플릿 엔진으로 분리하면 디자인 변경이 더 쉬워집니다

Stage 7. 챗봇 시스템 프롬프트 자동 생성 (prdt_optn_011)

7-1. 듀얼 모드 분기 설계

- 캐릭터(prdt_optn_007) 존재 시 → 모드 A: 캐릭터 페르소나 챗봇
- 캐릭터 없을 시 → 모드 B: 공연 컨시어지 챗봇

7-2. 모드 A: 캐릭터 페르소나 프롬프트 구조

1. 페르소나 정의 (1인칭 캐릭터)
2. 시대 · 세계관
3. 핵심 줄거리
4. 함께 등장하는 인물들
5. 행동 원칙 (페르소나 유지 / 모드 전환 / 불확실성 처리)

6. 공연 실제 정보 (모드 전환 시 안내용)
7. 안전 · 품질 규칙
8. 캐릭터별 맞춤 첫인사

7-3. 모드 B: 공연 컨시어지 프롬프트 구조

1. 챗봇 정체성 (친절한 안내원)
2. 공연 기본 정보
3. 시대 · 작품 배경
4. 작품 소개
5. 행동 원칙 (정보 안내 / 추천 / 불확실성)
6. 어조 가이드 (존댓말 · 이모지 · 간결성)
7. 안전 · 품질 규칙
8. 표준 첫인사

7-4. 공통 핵심 원칙

- 불확실한 정보는 추측 금지 → 상세 페이지 안내로 유도
- 모드 전환 메커니즘 (페르소나형도 실제 정보 질문에는 정확히 답변)
- 출처 명시 (모든 공연 정보 안내에 상세 페이지 URL 포함)

[*] 재사용 팁: 프롬프트 템플릿을 별도 .j2 파일로 분리하면, 톤 · 구조 변경 시 한 곳만 수정하면 됨

[■] 품질 관리 체크리스트

Data Quality (데이터 품질)

- ☐ 모든 텍스트 정규화 완료 (줄바꿈/탭/제어문자 제거)
- ☐ CSV는 UTF-8 BOM + QUOTE_ALL + CRLF로 저장
- ☐ XLSX 백업 파일 동시 생성 (HTML 같은 복잡 텍스트는 XLSX 권장)
- ☐ 결과를 pandas로 재로드해 행/컬럼 수 검증
- ☐ '기타' · 미분류 항목 수동 확인

Content Quality (콘텐츠 품질)

- ☐ 시대 배경의 연도 · 인물 사실 확인 (특히 실존 인물)
- ☐ 캐릭터 attribute는 챗봇 페르소나로 변환 가능한 수준의 디테일
- ☐ 줄거리는 스포일러 적정선 유지 (감상 흥미 보존)
- ☐ 일반 공연은 분야별 표준 문구로 일관성 유지

Chatbot Quality (챗봇 프롬프트)

- ☐ 캐릭터별 첫인사가 시대 · 성격을 반영
- ☐ 모드 전환 규칙 명확히 기술
- ☐ URL · 문의처 등 사실 정보는 변수로 주입
- ☐ 안전 규칙(욕설 · 차별 · 정치) 포함

[■] 최종 데이터 스키마 (19개 컬럼)

#	필드명	단계	유형	활용
1	prdt_tit	S1	텍스트	상품명
2	prdt_desc	S1	HTML	원본 설명
3	prdt_href_url	S1	URL	상세 페이지
4	prdt_thumb_src	S1	URL	썸네일
5	prdt_place	S1	텍스트	장소
6	prdt_optn_001	S1	텍스트	기간
7	prdt_optn_004	S4	텍스트	분야 (추론)
8	prdt_optn_005	S3	텍스트	시간 (스크래핑)
9	prdt_optn_006	S3	텍스트	요금 (스크래핑)
10	prdt_optn_007	S5	JSON	캐릭터
11	prdt_optn_009	S5	텍스트	시대 배경
12	prdt_optn_010	S5	텍스트	핵심 줄거리
13	prdt_optn_011	S7	텍스트	챗봇 프롬프트
14	prdt_apply_at_st	S1	YYYYMMDD	시작일
15	prdt_apply_at_en	S1	YYYYMMDD	종료일
16	ctgr_id	S2	코드	지역 ID
17	ctgr_nm	S2	텍스트	지역명
18	prdt_contact	S1	텍스트	문의처
19	prdt_ctts	S6	HTML	통합 상세 HTML

[*] 번호 점프 의미: 008 슬롯을 비워둔 것은 향후 태그/관람등급/추천대상 같은 추가 메타데이터용 예약

[] 재사용 시 권장 작업 흐름

① 새 데이터셋 준비

- 원천 JSON/CSV를 받아 1차 컬럼 매핑표 작성
- 키워드 사전(지역·분야)을 도메인에 맞게 보강

② 자동화 가능한 단계 먼저 실행

- Stage 1 (파싱·정규화) → Stage 2 (분류) → Stage 4 (분야 추론) → Stage 6 (HTML)
- 이 4단계는 100% 자동화 가능 → 가장 먼저 처리

③ 외부 의존 단계 분리

- Stage 3 (스크래핑) → 로컬에서 별도 스크립트로 실행

④ 콘텐츠 풍부화는 점진적으로

- 1차: AI가 알고 있는 유명 작품 우선 채움
- 2차: 웹 검색으로 사실 확인
- 3차: 도메인 전문가가 보강

⑤ 챗봇 프롬프트 자동 생성

- Stage 5 데이터가 채워지면 Stage 7은 100% 자동
- 템플릿 수정으로 톤·페르소나 변경 가능

⑥ 버저닝 관리

- v1.csv (기본 파싱) → v2 (분야/시간/요금) → ... → v7 (챗봇 프롬프트 완성)
- 각 버전을 보존해 회귀 시 비교 검증 가능

[■] 추천 기술 스택

단계	기술
데이터 파싱·가공	Python + pandas
웹 스크래핑	requests + BeautifulSoup4 (정적) / Playwright (동적)
출력 포맷	openpyxl (XLSX) + csv 표준 라이브러리 (CSV)
HTML 템플릿	Tailwind CSS (CDN)
챗봇 프롬프트	Jinja2 (선택) / f-string
검증	pandas + 통계 출력

[] 향후 확장 아이디어

추가 메타데이터 슬롯

- prdt_optn_008 → 관람 등급 / 연령 제한
- prdt_optn_012 → 관람 포인트 / 추천 대상
- prdt_optn_013 → 자주 묻는 질문 (Few-shot 예시)
- prdt_optn_014 → TTS 음성 톤 가이드 (성별/연령/감정)

챗봇 고도화

- 캐릭터별 명대사 / 명장면 JSON
- 다국어 프롬프트 자동 번역
- 임베딩 기반 유사 작품 추천

운영 자동화

- 신규 공연 추가 시 자동 메타데이터 생성 파이프라인
- '기타' 분류 케이스 알림 → 키워드 사전 보강 루프
- 챗봇 대화 로그 기반 프롬프트 자동 개선

[■] 핵심 교훈 (Lessons Learned)

1. CSV 깨짐의 주범은 줄바꿈 → 모든 텍스트는 단일 라인화 + QUOTE_ALL + UTF-8 BOM

2. XLSX는 복잡 텍스트(HTML/JSON)에 더 안정적 → 백업 포맷으로 항상 함께 제공

3. 분류 매칭은 우선순위 순서가 핵심 → 더 구체적인 키워드를 먼저 검사

4. 샌드박스 네트워크 제약 시 로컬 실행 스크립트로 우회

5. 풍부화 사전(CHARACTERS/ERA/PLOT)은 코드와 분리하면 유지보수 용이

6. 챗봇 프롬프트는 듀얼 모드 분기가 핵심 — 데이터 가용성에 따라 자동 적응

7. 버저닝(v1~v7)으로 단계별 산출물을 모두 보존

[*] 이 SOP는 공연 도메인뿐 아니라 다음 분야에도 그대로 적용 가능

- 전시 · 박물관 콘텐츠 (작품 · 작가 · 시대 · 소장처)

- 도서 · 교육 콘텐츠 (저자 · 시대 · 인물 · 줄거리)
- 여행 · 관광지 (지역 · 역사 · 인물 · 스토리텔링)
- 영화 · 드라마 · 게임 IP (캐릭터 · 세계관 · 플롯)

본 가이드는 다음 프로젝트에서 그대로 재사용할 수 있도록 표준화된 SOP입니다.
Stage별 산출물 검증 체크리스트 또는 Python 스크립트 템플릿 패키지가 필요하시면 별도
요청 가능합니다.