

공연 메타데이터 챗봇화 프로세스 정립 가이드

Standard Operating Procedure (SOP)

v2.0 · 2026.06 · + 프로세스 시각화 추가

본 문서는 공연 데이터를 챗봇이 활용 가능한 메타데이터로 가공한 전 과정과,
향후 재활용 가능한 표준 프로세스(7단계)를 정리한 운영 가이드입니다.

v2에서는 3종의 시각 흐름도(Chart A · B · C)가 추가되어 한눈에 파악할 수
있습니다.

[■] 프로젝트 개요

항목	내용
목표	외부 공공/민간 콘텐츠 목록(예: 문화체육관광부 공연정보)을 챗봇 학습용 메타데이터로 가공
입력	비정형 JSON 또는 CSV (필드명 · 구조 통일되지 않음)
출력	19개 컬럼 정형 데이터 (Excel + CSV) — DB 적재 및 챗봇 시스템 프롬프트 즉시 활용
소요 단계	7단계 (입력 정제 → 분류 → 보강 → 풍부화 → 페르소나 → 프롬프트 → 검증)
결과 활용	상품 상세 페이지(HTML), 카테고리 필터링, AI 챗봇 페르소나, 검색 · 추천 시스템

[■] 7단계 표준 프로세스 (Stage 1 ~ 7)

각 단계의 핵심 활동과 산출 컬럼을 요약합니다. 상세 시각 흐름은 다음 '프로세스 시각화' 섹션 참고.

Stage 1. 원천 데이터 수집 및 1차 파싱

활동: JSON/CSV 파싱 → 필드 매핑 → 텍스트 정규화(줄바꿈 제거)

→ 산출: prdt_tit, prdt_desc, prdt_href_url, prdt_thumb_src, prdt_place, prdt_optn_001, prdt_apply_at_st/en, prdt_contact (9개)

Stage 2. 카테고리(지역) 자동 분류

활동: 3-Tier 매칭: 특수규칙 → 장소 → 연락처 → 제목 (실패 시 '기타' 폴백)

→ 산출: ctgr_id, ctgr_nm (2개)

Stage 3. 외부 페이지 스크래핑 보강

활동: 분야/시간/요금 추출, 3중 안전망 파싱(/ → 정규식 → 전체텍스트)

→ 산출: prdt_optn_005 (시간), prdt_optn_006 (요금) (2개)

Stage 4. 휴리스틱 분류 (분야 자동 추론)

활동: 우선순위 키워드 매핑 + 기본값('공연') 폴백

→ 산출: prdt_optn_004 (분야) (1개)

Stage 5. 콘텐츠 풍부화

활동: 캐릭터 JSON · 시대 배경 · 핵심 줄거리 작성 (AI지식 + 웹검색 + 도메인전문가)

→ 산출: prdt_optn_007 (캐릭터), prdt_optn_009 (시대), prdt_optn_010 (줄거리) (3개)

Stage 6. 상품 상세 HTML 자동 생성

활동: Tailwind 컴포넌트 조합, 단일 라인 압축 (CSV 호환성)

→ 산출: prdt_ctts (1개)

Stage 7. 챗봇 시스템 프롬프트 자동 생성

활동: 듀얼 모드 분기 (캐릭터 페르소나 / 공연 컨시어지)

→ 산출: prdt_optn_011 (1개)

[*] 다음 페이지부터 3종의 시각 흐름도(Chart A · B · C)로 전체 프로세스를 한눈에 확인할 수 있습니다.

[■] 프로세스 시각화 (Process Visualization)

아래 3종의 차트는 본 SOP의 핵심 흐름을 한눈에 파악할 수 있도록 시각화한 것입니다.

Chart A — 7단계 표준 프로세스 흐름도

각 Stage의 활동 · 산출 컬럼을 색상 코드와 화살표로 연결하여 입력→최종 출력까지의 전체 흐름을 표현했습니다.

[Chart A] 7단계 표준 프로세스 흐름도

Performance Metadata → Chatbot SOP — Main Flow




위 흐름도는 Stage 1(원천 파싱)부터 Stage 7(챗봇 프롬프트)까지의 데이터 가공 파이프라인을 나타냅니다.

Chart B — 데이터 스키마 누적 진화도

Stage별로 어떤 컬럼이 추가되는지, 그리고 최종 19개 컬럼이 어떻게 누적되는지 시각화했습니다. 각 컬럼 블록의 색상은 해당 컬럼을 생성한 Stage를 의미합니다.

[Chart B] 데이터 스키마 누적 진화도

Stage별로 새 컬럼이 누적되어 최종 19개 정형 컬럼 완성



■ 최종 누적: 19개 컬럼 · S1(9) + S2(2) + S3(2) + S4(1) + S5(3) + S6(1) + S7(1) = 19


$9(S1) + 2(S2) + 2(S3) + 1(S4) + 3(S5) + 1(S6) + 1(S7) =$ 총 19개 컬럼이 단계적으로 누적됩니다.

Chart C — 챗봇 모드 자동 분기 의사결정 트리

Stage 7에서 챗봇 프롬프트를 생성할 때, 데이터에 캐릭터 정보(prdt_optn_007)가 있는지에 따라 두 가지 모드로 자동 분기되는 의사결정 흐름을 나타냅니다.

[Chart C] 챗봇 모드 자동 분기 의사결정 트리

데이터 가용성에 따라 prdt_optn_011 자동 생성 모드 결정



100건의 입력 중 14건은 캐릭터 페르소나형(모드 A), 86건은 공연 컨시어지형(모드 B)으로 자동 생성되었습니다.

[■] 품질 관리 체크리스트

Data Quality (데이터 품질)

- | |
|---|
| ☐ 모든 텍스트 정규화 완료 (줄바꿈/탭/제어문자 제거) |
| ☐ CSV는 UTF-8 BOM + QUOTE_ALL + CRLF로 저장 |
| ☐ XLSX 백업 파일 동시 생성 (HTML 같은 복잡 텍스트는 XLSX 권장) |
| ☐ 결과를 pandas로 재로드해 행/컬럼 수 검증 |
| ☐ '기타' · 미분류 항목 수동 확인 |

Content Quality (콘텐츠 품질)

- | |
|---|
| ☐ 시대 배경의 연도 · 인물 사실 확인 (특히 실존 인물) |
| ☐ 캐릭터 attribute는 챗봇 페르소나로 변환 가능한 수준의 디테일 |
| ☐ 줄거리는 스포일러 적정선 유지 |
| ☐ 일반 공연은 분야별 표준 문구로 일관성 유지 |

Chatbot Quality (챗봇 프롬프트)

- | |
|--|
| ☐ 캐릭터별 첫인사가 시대 · 성격을 반영 |
| ☐ 모드 전환 규칙 명확히 기술 |
| ☐ URL · 문의처 등 사실 정보는 변수로 주입 |
| ☐ 안전 규칙(욕설 · 차별 · 정치) 포함 |

[■] 최종 데이터 스키마 (19개 컬럼)

#	필드명	단계	유형	활용
1	prdt_tit	S1	텍스트	상품명
2	prdt_desc	S1	HTML	원본 설명
3	prdt_href_url	S1	URL	상세 페이지
4	prdt_thumb_src	S1	URL	썸네일
5	prdt_place	S1	텍스트	장소
6	prdt_optn_001	S1	텍스트	기간
7	prdt_optn_004	S4	텍스트	분야 (추론)
8	prdt_optn_005	S3	텍스트	시간 (스크래핑)
9	prdt_optn_006	S3	텍스트	요금 (스크래핑)
10	prdt_optn_007	S5	JSON	캐릭터
11	prdt_optn_009	S5	텍스트	시대 배경
12	prdt_optn_010	S5	텍스트	핵심 줄거리
13	prdt_optn_011	S7	텍스트	챗봇 프롬프트
14	prdt_apply_at_st	S1	YYYYMMDD	시작일
15	prdt_apply_at_en	S1	YYYYMMDD	종료일
16	ctgr_id	S2	코드	지역 ID
17	ctgr_nm	S2	텍스트	지역명
18	prdt_contact	S1	텍스트	문의처
19	prdt_ctts	S6	HTML	통합 상세 HTML

[*] 번호 점프 의미: 008 슬롯을 비워둔 것은 향후 태그/관람등급/추천대상 같은 추가 메타데이터용 예약

[] 재사용 시 권장 작업 흐름

- ① 새 데이터셋 준비
 - 원천 JSON/CSV → 1차 컬럼 매핑표 작성
 - 키워드 사전(지역·분야)을 도메인에 맞게 보강
- ② 자동화 단계 먼저 실행
 - Stage 1 → 2 → 4 → 6 (100% 자동화 가능)
- ③ 외부 의존 단계 분리
 - Stage 3 (스크래핑) → 로컬에서 별도 스크립트로 실행
- ④ 콘텐츠 풍부화는 점진적으로
 - 1차: AI 지식 2차: 웹 검색 3차: 도메인 전문가
- ⑤ 챗봇 프롬프트 자동 생성
 - Stage 5 완료 시 Stage 7은 100% 자동
- ⑥ 버저닝 관리
 - v1.csv → v2 → ... → v7 (각 단계 산출물 보존)

[■] 추천 기술 스택

단계	기술
데이터 파싱·가공	Python + pandas
웹 스크래핑	requests + BeautifulSoup4 (정적) / Playwright (동적)
출력 포맷	openpyxl (XLSX) + csv 표준 라이브러리 (CSV)
HTML 템플릿	Tailwind CSS (CDN)
챗봇 프롬프트	Jinja2 / f-string
검증	pandas + 통계 출력

[] 향후 확장 아이디어

- prdt_optn_008 → 관람 등급 / 연령 제한
- prdt_optn_012 → 관람 포인트 / 추천 대상
- prdt_optn_013 → 자주 묻는 질문 (Few-shot 예시)
- prdt_optn_014 → TTS 음성 톤 가이드

[■] 핵심 교훈 (Lessons Learned)

1. CSV 깨짐의 주범은 줄바꿈 → 단일 라인화 + QUOTE_ALL + UTF-8 BOM
2. XLSX는 복잡 텍스트에 더 안정적 → 백업 포맷으로 항상 함께 제공
3. 분류 매칭은 우선순위 순서가 핵심
4. 샌드박스 네트워크 제약 시 로컬 실행 스크립트로 우회
5. 풍부화 사전은 코드와 분리하면 유지보수 용이
6. 챗봇 프롬프트는 듀얼 모드 분기가 핵심
7. 버저닝(v1~v7)으로 단계별 산출물 모두 보존

본 가이드(v2)는 시각 흐름도가 추가되어 더 명확한 SOP가 되었습니다.
다음 프로젝트에서 그대로 재사용 가능합니다.